



RNN（循环神经网络）是深度学习中用于处理序列数据的经典模型，广泛应用于文本分类任务，如情感分析。情感分析任务的目标是根据评论的内容判断其为好评还是差评。以下是一个基于RNN模型实现情感分析的基本原理概述，结合了你提到的具体细节。

情感分析的输入是一个句子（如“I hate this boring movie”），首先需要将每个单词转换为一个向量表示，通常使用词嵌入（Word Embeddings）方法。假设每个单词用一个100维的张量表示，那么整句话就是一个形状为 [5, 100] 的张量（假设句子中有5个单词）。通过RNN模型处理这个输入序列，RNN会逐步读取句子的每个单词，并根据之前的状态来更新当前的状态。最终，RNN会生成一个表示整个句子含义的固定长度向量，作为输入传递给后续的分类层，通过Softmax分类器计算概率 $P(pos|x)$ ，判断评论的情感。




但是随着句子长度的增加，参数量也会随之增加，尤其是每个单词都通过一个独立的权重矩阵进行映射时，参数量会显得非常庞大，尤其是在处理长文本时，会造成较高的计算成本和内存消耗。为了解决这个问题，你可以采用 **权值共享**（Weight Sharing）的方法。权值共享指的是让不同时间步的参数（如 w 和 b ）共享相同的权重，而不是每个时间步使用一组独立的参数。这样做可以显著减少模型的参数量，同时也能降低计算复杂度。



在序列数据处理（尤其是情感分析任务）中，单个单词的特征向量通常不足以捕获整体句子的上下文信息。为了更好地理解整个句子的语义，我们需要一个能够维护上下文信息的机制，这也是 **循环神经网络（RNN）** 的优势所在。RNN能够通过隐藏状态（如 h_0 、 h_1 、 h_2 等）在每个时间步上持续传递和更新语境信息，从而捕捉到长期的依赖关系。在处理情感分析任务时，整个句子的情感并不是通过孤立的单词来决定的，而是依赖于整个句子的上下文信息。每个单词的理解需要结合前后文的信息，这就需要一个 **持续更新的隐藏状态（hidden state⁺）** 来携带和传递上下文。每个时间步的输入不仅包括当前单词的特征向量，还包括上一时刻的隐藏状态。这样，RNN就能够“记住”前面时间步的信息，并将其与当前的输入信息结合起来，从而捕捉整个句子的上下文信息。

假设我们有一个句子：“I hate this boring movie”。每个单词都有对应的输入特征向量 x_t ，而每个时刻的隐藏状态 h_t 则是依赖于当前输入 x_t 和上一时刻的隐藏状态 $h_{(t-1)}$ 。




简化后的 RNN 过程可以如下描述：假设输入特征为 x ，其形状为 $[5, 3, 100]$ ，表示为

- 5：句子中包含 5 个单词。
- 3：一个 batch 中包含 3 个句子。


- **100**：每个单词使用一个 100 维的特征向量表示。

对于每个句子，输入的特征张量 x 的形状为 $[5, 100]$ ，即每个句子包含 5 个单词，每个单词由一个 100 维的特征向量表示。一个 batch 的输入 x 形状为 $[3, 5, 100]$ ，表示 3 个句子，每个句子有 5 个单词，每个单词 100 维的向量。RNN 在每个时间步都会根据当前输入和上一时刻的隐藏状态来更新当前时刻的隐藏状态。公式如下：

$$h_t = f(W_{xh}x_t + W_{hh}h_t) = \tanh(W_{xh}x_t + W_{hh}h_t), \quad y_t = W_{hy}h_t$$




展开之后可以得到：



那么如何进行训练RNN呢？RNN 的训练主要依赖于反向传播算法[★]（Backpropagation Through Time, BPTT），结合前向传播和误差的反向传播来更新模型的参数，即误差从最后一个时间步逐步向前传播，更新参数 W_{in} 、 W_{hh} 、 W_o 。损失函数为：

$$E_t = \frac{1}{2} \sum_t (y_t - \hat{y}_t)^2$$

How To Train?



$$h_0, w_{ih}, w_{hh}$$

$$h_t = \tanh(W_I x_t + W_R h_{t-1})$$
$$y_t = W_O h_t$$

$$\frac{\partial E_t}{\partial W_R} = \sum_{i=0}^t \frac{\partial E_t}{\partial y_t} \frac{\partial y_t}{\partial h_t} \frac{\partial h_t}{\partial h_i} \frac{\partial h_i}{\partial W_R}$$

$$\frac{\partial h_t}{\partial h_i} = \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial h_{t-2}} \cdots \frac{\partial h_{i+1}}{\partial h_i} = \prod_{k=i}^{t-1} \frac{\partial h_{k+1}}{\partial h_k}$$

$$f = \tanh(x)$$
$$\frac{\partial h_{k+1}}{\partial h_k} = \text{diag}(f'(W_I x_i + W_R h_{i-1})) W_R$$

$$\frac{\partial h_k}{\partial h_1} = \prod_i^k \text{diag}(f'(W_I x_i + W_R h_{i-1})) W_R$$

知乎@禾风hefeng

CSDN @禾风hefeng